

## PROJETO 3

TEOREMA DO LIMITE CENTRAL (TLC)

DISTRIBUIÇÃO DE  $\frac{\bar{X}-\mu}{\sigma/\sqrt{n}}$  E DE  $\frac{\bar{X}-\mu}{S/\sqrt{n}}$

### ESTUDO DA DISTRIBUIÇÃO DA MÉDIA AMOSTRAL ( $\bar{X}$ ) VIA SIMULAÇÃO

#### OBJETIVO:

O objetivo deste projeto é que o aluno seja capaz de **compreender e explicar o resultado do Teorema do Limite Central (TLC) por meio de simulação**, uma vez que a demonstração teórica é complexa e requer conhecimento de outras teorias avançadas.

A seguir, apresentamos a definição da média amostral e o resultado descrito no Teorema do Limite Central.

#### Definição:

Seja  $X$  uma variável aleatória de interesse com distribuição qualquer, cuja média populacional e variância populacional são, usualmente, denotadas por  $E(X) = \mu$  e  $\text{Var}(X) = \sigma^2$ .

Para estimar a **média populacional**,  $\mu$ , utiliza-se o estimador **Média Amostal** definido por:

$$\bar{X} = \frac{\sum_{i=1}^n X_i}{n}.$$

#### Teorema do Limite Central:

Para uma amostra aleatória  $(X_1, \dots, X_n)$  retirada de uma população cuja variável de interesse  $X$  tem média  $\mu$  e variância  $\sigma^2$ , então a distribuição de da média amostral ( $\bar{X}$ ) se aproxima de uma distribuição normal com média  $\mu$  e variância  $\sigma^2/n$ , quando  $n$  tende ao infinito (suficientemente grande).

Parafraseando, seja  $X$  uma variável aleatória com média  $\mu$  e variância  $\sigma^2$  e seja  $(X_1, \dots, X_n)$  uma amostra aleatória retirada de  $X$ , então  $\bar{X} \sim N\left(\mu; \frac{\sigma^2}{n}\right)$ , quando  $n$  tende ao infinito (suficientemente grande). Mesmo que  $X$  não tenha distribuição normal

## O QUE DEVE SER FEITO:

Nesse projeto, você e sua equipe (até DUPLA) deverão fazer um estudo de **SIMULAÇÃO** para visualizar graficamente a distribuição da média amostral, calcular o valor médio e a variância dessas médias e interpretar esses resultados.

Para tanto, siga os seguintes passos:

1. Construir os valores da população:
  - a. Definir uma distribuição teórica para variável  $X$  e definir valor(es) para representar o(s) parâmetro(s) da sua distribuição teórica escolhida.
    - i. Por exemplo, se definir que  $X \sim \text{Poisson}(\lambda)$ , então, para essa distribuição teórica, tem-se que  $E(X) = \text{Var}(X) = \lambda$ . Logo, será necessário definir apenas um valor para  $\lambda$ , por exemplo,  $\lambda = 4$ .
  - b. Sortear aleatoriamente um número muito grande de valores da sua distribuição teórica definida no item 1.a. Esses valores gerados aleatoriamente irão caracterizar todos os valores da sua população. Pesquise o método `.rvs` da sua distribuição no Python.
    - i. Continuando o exemplo acima da Poisson, aqui seria `stats.poisson.rvs(mu=4, loc=0, size=1000000)`.
  - c. Calcule a média e a variância desses valores, os quais irão representar, respectivamente, a média populacional  $\mu$  e a variância populacional  $\sigma^2$ .
2. Construir a distribuição da média amostral:
  - a. Inicialmente, considere  $n = 2$ .
  - b. Sorteie  $n$  valores entre os muitos gerados no item 1b. Para tanto, pesquise o método `.random.choice` do `numpy`.
  - c. Calcule a média amostral dos valores obtidos no item anterior.
  - d. Repita os itens 2.b e 2.c por 10.000 vezes. Nesse caso, deverá ter 10.000 médias amostrais.
  - e. Considerando essas 10.000 médias amostrais, construa um histograma com esses valores, calcule a média e a variância dessas médias amostrais.
  - f. Interprete os resultados confrontando com o resultado aguardado via TLC.
3. Repita o item 2 para  $n = 4$ ;  $n = 20$ ;  $n = 50$ .
4. Faça uma conclusão geral explicando tudo o que aconteceu, o que é para ser visto e como se relaciona com o TLC. Faça essa explicação como se alguém pudesse aprender o TLC a partir de sua simulação.

Ainda, para compreender o resultado do TLC, é necessário observar que a sequência  $(X_1, \dots, X_n)$  é chamada de **amostra aleatória**, ou seja, as variáveis dessa sequência são independentes e identicamente distribuídas a  $X$ .

Para tanto, siga os seguintes passos:

- i. Considerando as simulações de  $n = 50$ , por exemplo, guarde sempre o terceiro e o décimo quinto valores sorteados em cada uma das 10.000 vezes. Ao final, deverá ter duas listas de 10.000 valores cada, uma que irá representar  $X_3$  e outra que irá representar  $X_{15}$ .
- ii. Faça o histograma apenas com os valores  $X_3$ .
- iii. Faça o histograma apenas com os valores  $X_{15}$ .
- iv. Compare com a distribuição de  $X$  com que escolheram no item 1 acima. Elas são iguais? Ou seja,  $X_3$  e  $X_{15}$  são identicamente distribuídas a  $X$ ?
- v. Calcule a correlação entre  $X_3$  e  $X_{15}$  e verifique se essa correlação é próxima de zero, indicando a independência entre elas.

## ESTUDO DA DISTRIBUIÇÃO DE $\frac{\bar{X} - \mu}{\sigma / \sqrt{n}}$ E DE $\frac{\bar{X} - \mu}{S / \sqrt{n}}$ VIA SIMULAÇÃO

### **OBJETIVO:**

Outro objetivo deste projeto é que aluno seja capaz de **compreender a distribuição da padronização da média amostral utilizando o verdadeiro desvio padrão  $\sigma$  e a distribuição da padronização da média amostral utilizando o desvio padrão amostral  $S$ , ambos por meio de simulação.**

As distribuições dessas padronizações são importantes na Estatística e muito utilizadas em técnicas inferenciais. Assim, as distribuições que seguem tais padronizações são:

#### **Resultado 1:**

Para uma amostra aleatória  $(X_1, \dots, X_n)$  retirada de uma população cuja variável de interesse  $X$  tem média  $\mu$  e variância  $\sigma^2$ , então a distribuição de:

$$\frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \sim N(0, 1),$$

quando  $n$  tende ao infinito (suficientemente grande).

Se  $X$  tiver distribuição normal, então o resultado acima segue uma distribuição normal padrão exata, não importando o tamanho amostral.

#### **Resultado 2:**

Para uma amostra aleatória  $(X_1, \dots, X_n)$  retirada de uma população cuja variável de interesse  $X$  tem distribuição Normal com média  $\mu$  e variância  $\sigma^2$ , então a distribuição de:

$$\frac{\bar{X} - \mu}{S / \sqrt{n}} \sim t_{(n-1)},$$

sendo  $S$  o desvio padrão amostral da sequência  $(X_1, \dots, X_n)$ . Assim, a padronização da média amostral assumindo o desvio padrão amostral segue distribuição t-Student com  $n - 1$  graus de liberdade.

## **O QUE DEVE SER FEITO:**

Aqui, devem visualizar graficamente a distribuição da padronização da média amostral considerando desvio padrão populacional e a distribuição da padronização considerando desvio padrão amostral.

Para tanto, siga os seguintes passos:

1. Construir os valores da população:
  - a. Definir valores para a distribuição normal atribuída à variável  $X$  e definir valor(es) para representar o(s) parâmetro(s) da sua distribuição teórica escolhida.
    - i. Por exemplo, se definir que  $X \sim \text{Normal}(\mu, \sigma^2)$ , então, para essa distribuição teórica, será necessário definir um valor para  $\mu$  e outro para  $\sigma^2$ . Por exemplo,  $\mu = 10$  e  $\sigma^2 = 4$ .
  - b. Sortear aleatoriamente um número muito grande de valores da sua distribuição teórica definida no item 1.a. Esses valores gerados aleatoriamente irão caracterizar todos os valores da sua população. Pesquise o método `.rvs` da sua distribuição no Python.
    - i. Continuando o exemplo acima da Normal, aqui seria `stats.norm.rvs(loc=10, scale=2, size=1000000)`.
  - c. Calcule a média e a variância desses valores, os quais irão representar, respectivamente, a média populacional  $\mu$  e a variância populacional  $\sigma^2$ .
2. Construir a distribuição da média amostral:
  - a. Inicialmente, considere  $n = 4$ .
  - b. Sorteie  $n$  valores entre os muitos gerados no item 1b. Para tanto, pesquise o método `.random.choice` do `numpy`.
  - c. Calcule a média amostral  $\bar{x}$  e o desvio padrão amostral  $s$  dos valores obtidos no item anterior.
  - d. Calcule  $z = \frac{\bar{x} - \mu}{\sigma / \sqrt{n}}$  e de  $t = \frac{\bar{x} - \mu}{s / \sqrt{n}}$ .
  - e. Repita os itens 2.b a 2.d por 10.000 vezes. Nesse caso, deverá ter 10.000 valores  $z$  e 10.000 valores  $t$ .
  - f. Considerando esses 10.000 valores de  $z$ , construa um histograma com os valores de  $z$  e coloque a f.d.p. da distribuição normal padrão ( $N(0,1)$ ).
  - g. Considerando esses 10.000 valores de  $t$ , construa um histograma com os valores de  $t$  e coloque a f.d.p. da distribuição t-Student com  $n - 1$  graus de liberdade.
  - h. Interprete os resultados confrontando com os Resultados 1 e 2.

3. Repita o item 2 para  $n = 20$ ;  $n = 50$ ;  $n = 300$ .
4. Faça uma conclusão geral explicando todos os resultados obtidos com a simulação confrontados com os resultados teóricos.

**ENTREGÁVEIS ESPERADOS E DATAS:**

Item	Data	Descrição
Entrega 1	13/04/2017 Até às 15h30	<ol style="list-style-type: none"><li>1. Criar pasta Projeto 3</li><li>2. Publicar arquivo Python sobre o Projeto 3 Entrega 1 trabalhado em sala de aula.</li><li>3. Os dois integrantes do grupo devem fazer isso.</li></ol>
Entrega Final	18/04/2017 Até às 23h59	<ol style="list-style-type: none"><li>1. Publicar, na pasta Projeto 3, o arquivo Python sobre o Projeto 3 FINAL.</li><li>2. Os dois integrantes do grupo devem fazer isso.</li></ol>

## RUBRICS DE AVALIAÇÃO DO OBJETIVO DE APRENDIZADO

Objetivo de aprendizado	Insatisfatório (I)	Em desenvolvimento (D)	Essencial (C)	Proficiente (B)	Avançado (A)
<b>Compreender o resultado do TLC via simulação</b>	Apresentou entregas insuficientes ou atrasadas fora do prazo combinado com o professor.	Escolheu um modelo para a variável X considerando valores para a média e a variância dessa variável.  A simulação não só é incompleta como também não dá o menor indicativo que seria possível simular o TLC.	Apresenta simulações mas não estão conforme as instruções deste enunciado deixando apenas ideia do comportamento da distribuição da média amostral.	Simulou exatamente como no enunciado e explica basicamente o TLC	Simulou exatamente como no enunciado  Procurou complementar a simulação com detalhes extra que reforcem a compreensão do TLC (fórmulas, gráficos, etc)  Explica o TLC a ponto de se poder estudar pelo seu notebook.
<b>Compreender a distribuição da padronização da média amostral utilizando desvio padrão populacional e utilizando o desvio padrão amostral</b>	Apresentou entregas insuficientes ou atrasadas fora do prazo combinado com o professor.	A simulação não só é incompleta como também não dá o menor indicativo que seria possível compreender a distribuição das padronizações da média amostral.	Apresenta simulações mas não estão conforme as instruções deste enunciado deixando apenas ideia do comportamento da distribuição das padronizações.	Simulou exatamente como no enunciado e explica basicamente a padronização da média amostral em ambos os contextos.	Simulou exatamente como no enunciado  Procurou complementar a simulação com detalhes extra que reforcem a compreensão das padronizações da média amostral e explica com clareza tais resultados..